Classificação de Flores Íris com k-NN: Análise Exploratória, PCA e Avaliação de Classificador

Gustavo Gabriel Ripka
GRR20203935

Arthur Barreto Godoi
GRR20224377

Departamento de Informática
Universidade Federal do Paraná – UFPR
Curitiba, Brasil

***Resumo*—Este trabalho realiza experimentos de classificação no dataset Íris, que contém comprimento e largura de sépalas e pétalas de três espécies de flores (*Iris setosa*, *Iris versicolor* e *Iris virginica*), com 50 amostras cada. Inicialmente calculamos média, desvio padrão e moda de cada variável, no conjunto geral e por categoria, além da frequência de cada categoria. Em seguida analisamos a relação entre comprimento e largura da sépala e da pétala por categoria via regressão linear e correlação de Pearson, e examinamos a distribuição das categorias nas quatro dimensões. A Análise de Componentes Principais (PCA) mostrou que duas componentes concentram 95,8% da variância total. Por fim, o dataset foi dividido em 80% para treino e 20% para teste, e um classificador k-NN foi ajustado por validação cruzada (melhor configuração: $k = 5$, distância euclidiana, acurácia média de 96,7% em validação cruzada), alcançando 93,3% de acurácia no conjunto de teste, com erros concentrados na fronteira entre *versicolor* e *virginica*.**

***Index Terms*—dataset Íris, análise exploratória, correlação, PCA, k-NN, validação cruzada.**

I. Introdução

Reconhecimento de padrões é uma tarefa central em visão computacional: dado um conjunto de medidas (atributos) de objetos, deseja-se atribuir a cada objeto uma categoria [1]. Um classificador supervisionado aprende essa correspondência a partir de exemplos rotulados, e sua avaliação honesta exige separar os dados usados para ajuste daqueles usados para teste [2].

Neste trabalho usamos o dataset Íris [3], [4], um dos conjuntos de dados mais conhecidos da literatura, formado por 150 flores igualmente distribuídas em três categorias. Cada flor é descrita por quatro medidas em centímetros: comprimento da sépala (CS), largura da sépala (LS), comprimento da pétala (CP) e largura da pétala (LP). O objetivo é percorrer o ciclo completo de um experimento de classificação: estatística descritiva, análise de relações entre variáveis, visualização da distribuição das categorias, redução de dimensionalidade com PCA e, por fim, separação das classes com o classificador k-vizinhos-mais-próximos (k-NN) [2].

O restante do relatório está organizado da seguinte forma: a Seção II descreve materiais e métodos; a Seção III apresenta a estatística descritiva; a Seção IV analisa as relações comprimento × largura; a Seção V examina a distribuição nas quatro dimensões; a Seção VI apresenta a PCA; a Seção VII descreve os experimentos de classificação com k-NN; e a Seção VIII conclui.

II. Materiais e Métodos

Os experimentos foram implementados em Python 3 com as bibliotecas NumPy, pandas, SciPy, Matplotlib e scikit-learn [6]. O dataset original do UCI Machine Learning Repository [4] foi usado na forma do arquivo `iris.data` (150 linhas, sem valores ausentes). Para reprodutibilidade, todas as operações aleatórias usaram semente fixa igual a 42.

A metodologia seguiu as etapas: (i) estatística descritiva geral e por categoria, com frequências; (ii) análise da relação comprimento × largura da sépala e da pétala por categoria, com regressão linear simples e coeficiente de correlação de Pearson r; (iii) matriz de dispersão das quatro variáveis para examinar a distribuição das categorias; (iv) PCA sobre dados padronizados (z-score); (v) divisão estratificada 80%/20% em treino/teste; e (vi) classificação com k-NN, com seleção de hiperparâmetros por validação cruzada em 5 partições (*5-fold cross-validation*) apenas no conjunto de treino, seguida de avaliação única no conjunto de teste [2].

III. Estatística Descritiva

A Tabela I resume média, desvio padrão e moda das quatro variáveis no conjunto geral (150 flores). As pétalas apresentam os maiores desvios padrão relativos (CP: 1,76 cm; LP: 0,76 cm), indicando alta variabilidade — reflexo direto das diferenças entre as espécies. As sépalas variam menos (CS: 0,83 cm; LS: 0,43 cm).

Tabela I
Estatística descritiva no conjunto geral ($n = 150$). Valores em cm.

Variável	Média	Desvio padrão	Moda
Comprimento sépala	5,84	0,83	5,0
Largura sépala	3,05	0,43	3,0
Comprimento pétala	3,76	1,76	1,5
Largura pétala	1,20	0,76	0,2

A Tabela II mostra as estatísticas por categoria. A frequência de cada categoria é idêntica: 50 flores (33,3%) de cada espécie, ou seja, o dataset é perfeitamente balanceado.

Observa-se um padrão claro de separação em tamanho de pétala: *setosa* tem pétalas pequenas (CP médio 1,46 cm), *versicolor* intermediárias (4,26 cm) e *virginica* grandes (5,55 cm), com intervalos quase disjuntos. As sépalas separam menos: *setosa* tem a maior largura média de sépala (3,42 cm) apesar do menor comprimento (5,01 cm), enquanto *virginica* tem as maiores sépalas em comprimento (6,59 cm).

Tabela II
MÉDIA ± DESVIO PADRÃO POR CATEGORIA ($n = 50$ CADA). VALORES EM CM.

Variável	Setosa	Versicolor	Virginica
Compr. sépala	5,01 ± 0,35	5,94 ± 0,52	6,59 ± 0,64
Largura sépala	3,42 ± 0,38	2,77 ± 0,31	2,97 ± 0,32
Compr. pétala	1,46 ± 0,17	4,26 ± 0,47	5,55 ± 0,55
Largura pétala	0,24 ± 0,11	1,33 ± 0,20	2,03 ± 0,28

IV. Relação Comprimento × Largura

A. Sépalas

A Fig. 1 mostra a dispersão comprimento × largura da sépala por categoria, com reta de regressão linear ajustada. As correlações de Pearson são moderadas e positivas nas três categorias: $r = 0{,}75$ para *setosa* ($p < 0{,}001$), $r = 0{,}53$ para *versicolor* ($p < 0{,}001$) e $r = 0{,}46$ para *virginica* ($p < 0{,}001$). Ou seja, dentro de cada espécie, sépalas mais longas tendem a ser também mais largas, com a relação mais forte em *setosa*. No plano sépala, porém, as categorias *versicolor* e *virginica* se sobrepõem fortemente — a variável sépala sozinha não separa bem essas duas espécies.

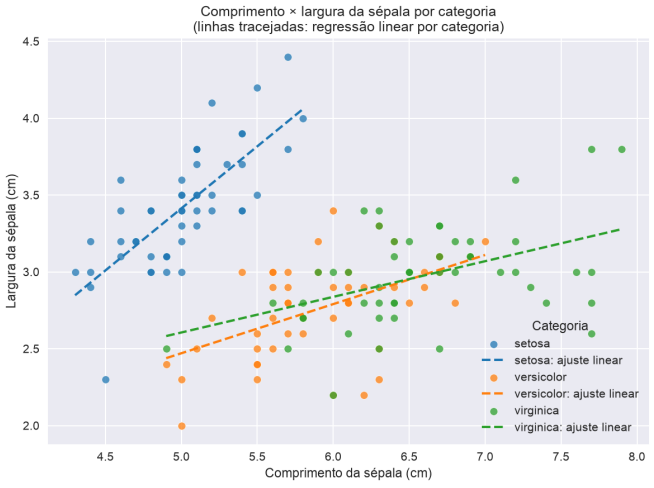


Figura 1. Comprimento × largura da sépala por categoria, com retas de regressão linear.

B. Pétalas

A Fig. 2 mostra o mesmo tipo de análise para as pétalas. As correlações são $r = 0{,}31$ para *setosa* ($p = 0{,}031$), $r = 0{,}79$ para *versicolor* ($p < 0{,}001$) e $r = 0{,}32$ para *virginica* ($p = 0{,}023$). A relação linear é forte apenas em *versicolor*; em *setosa* e *virginica* o tamanho da pétala varia pouco em largura, enfraquecendo a correlação. O ponto mais importante, porém, é a separação: no plano pétala, *setosa* fica completamente isolada (pétalas curtas e estreitas), e a fronteira entre *versicolor* e *virginica*, embora exista, ainda apresenta sobreposição parcial.

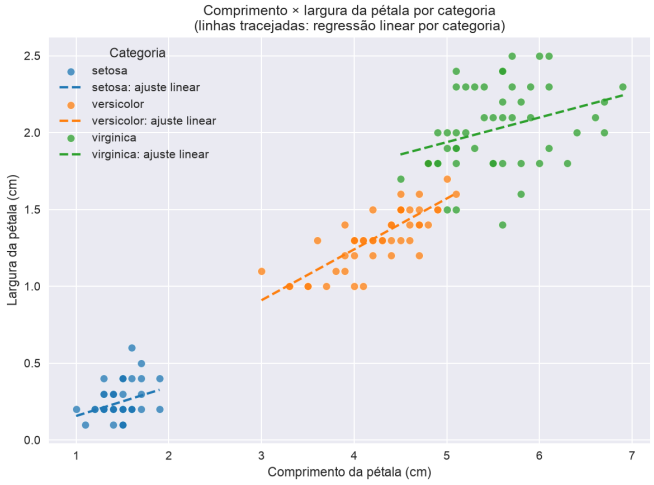


Figura 2. Comprimento × largura da pétala por categoria, com retas de regressão linear.

V. Distribuição nas Quatro Dimensões

A Fig. 3 apresenta a matriz de dispersão das quatro variáveis, com histogramas na diagonal. A leitura por pares de variáveis confirma: (i) *setosa* é linearmente separável das demais em praticamente qualquer par envolvendo pétalas; (ii) *versicolor* e *virginica* se misturam nos pares de sépalas e se separam parcialmente nos pares envolvendo comprimento de pétala, com melhor resultado quando CP e LP são combinadas. Os histogramas diagonais mostram ainda que as distribuições de CP e LP são claramente trimodais no conjunto geral — cada moda corresponde a uma espécie —, enquanto as variáveis de sépala têm distribuições unimodais sobrepostas.

VI. Análise de Componentes Principais

A PCA [5] projeta os dados em direções ortogonais de máxima variância. Aplicamos a PCA sobre os dados padronizados (média 0, desvio 1), etapa recomendada quando as variáveis têm escalas ou variabilidades diferentes. Os resultados (Fig. 4) mostram que a primeira componente principal (PC1) explica 72,8% da variância e a segunda (PC2) 23,0%, totalizando 95,8% com apenas duas dimensões — as demais componentes contribuem com apenas 3,7% (PC3) e 0,5% (PC4).

Os pesos (*loadings*) da PC1 são dominados pelas medidas de pétala (CP: 0,58; LP: 0,57) e pelo comprimento de sépala (0,52), com contribuição negativa pequena da largura de sépala ($-0{,}26$): PC1 é essencialmente um eixo de "tamanho geral da flor", com destaque para as pétalas. A PC2 é dominada pela largura de sépala (0,93), um eixo quase independente do primeiro.

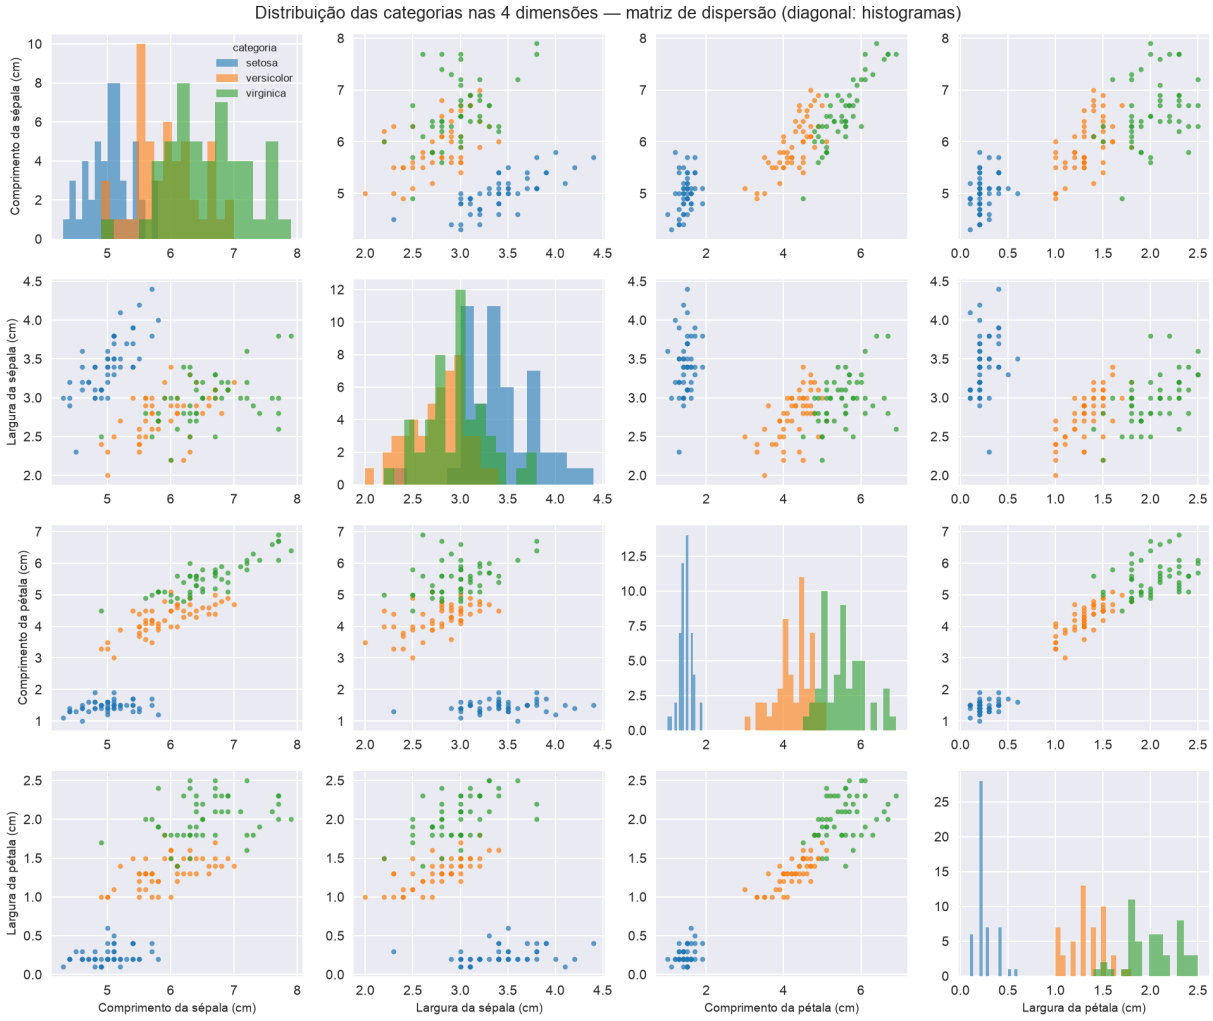


Figura 3. Matriz de dispersão das quatro variáveis (cm) com histogramas na diagonal.

Na projeção PC1 × PC2, *setosa* forma um grupo isolado, e *versicolor*/*virginica* formam grupos adjacentes com pequena sobreposição — consistente com a análise por pares. O resultado é interessante do ponto de vista prático: as 4 medidas podem ser reduzidas a 2 componentes com perda mínima de informação (95,8% da variância preservada), o que facilita visualização e pode reduzir custo de cálculo em classificadores por distância como o k-NN.

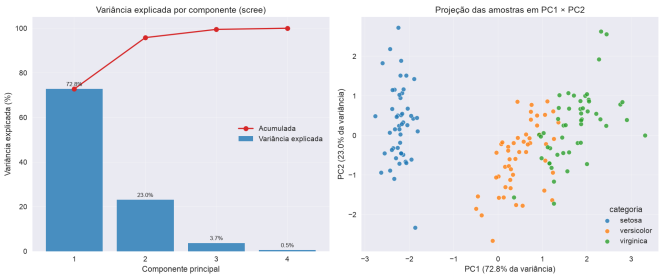


Figura 4. PCA sobre dados padronizados: variância explicada (esquerda) e projeção PC1 × PC2 (direita).

VII. Classificação com k-NN

A. Divisão treino/teste e metodologia

O dataset foi dividido em 80% para treino (120 amostras) e 20% para teste (30 amostras), com amostragem estratificada: 40/40/40 por categoria no treino e 10/10/10 no teste, preservando o balanceamento original.

O classificador k-NN [2] não constrói um modelo explícito: ele memoriza os exemplos de treino e classifica uma nova amostra pela maioria entre os k vizinhos mais próximos, segundo uma métrica de distância. Como o k-NN se baseia em distâncias, as variáveis foram padronizadas com `StandardScaler` ajustado apenas no treino, evitando que variáveis de escala maior dominem o cálculo [2]. Os hiperparâmetros $k \in \{1, 3, \ldots, 21\}$ e a métrica (euclidiana ou Manhattan) foram selecionados por *grid search* com validação cruzada de 5 partições no conjunto de treino.

B. Seleção de hiperparâmetros

A Fig. 5 mostra a acurácia média de validação cruzada em função de k para as duas métricas. A melhor configuração foi $k = 5$ com distância euclidiana (acurácia média de 96,7% $\pm$ 3,1%). O desempenho é estável em uma ampla faixa (k entre 3 e 21 fica acima de 95%), com degradação leve para k grandes, e a métrica euclidiana foi consistentemente igual ou superior à Manhattan.

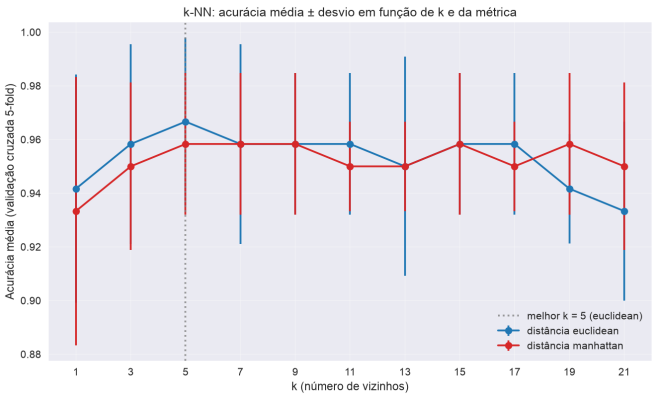


Figura 5. Acurácia média (5-fold) no treino em função de k, para distâncias euclidiana e Manhattan.

C. Resultados no teste

Com $k = 5$ e distância euclidiana, o modelo alcançou **acurácia de 93,3%** (28 acertos em 30) no conjunto de teste. A Tabela III mostra o relatório de classificação por classe: *setosa* é classificada perfeitamente (F1 = 1,00); os erros concentram-se na fronteira *versicolor–virginica*. A matriz de confusão (Fig. 6) confirma: as duas amostras erroneamente classificadas são *virginica* previstas como *versicolor* — exatamente a região de sobreposição identificada na análise exploratória e na PCA.

Tabela III
RELATÓRIO DE CLASSIFICAÇÃO NO CONJUNTO DE TESTE ($k = 5$, EUCLIDIANA).

Classe	Precisão	Revocação	F1	Suporte
Setosa	1,00	1,00	1,00	10
Versicolor	0,83	1,00	0,91	10
Virginica	1,00	0,80	0,89	10
Média macro	0,94	0,93	0,93	30

Vale registrar duas observações. Primeiro, $k = 1$ (NN puro, com padronização) obteve 96,7% neste teste particular; ainda assim mantivemos $k = 5$, escolhido exclusivamente com dados de treino/validação — usar o resultado do teste para trocar de modelo caracterizaria vazamento de informação. Segundo, rodando sem padronização o k-NN acertou as 30 amostras (100%). Isso não contradiz a recomendação do escalonamento [2]: no Íris as quatro variáveis têm escalas próximas (0,1–7,9 cm), então a padronização pouco altera as distâncias, e a diferença observada decorre de sorte amostral num teste pequeno (30 amostras). Em domínios com escalas heterogêneas (e.g., intensidades de pixel 0–255 combinadas com outras medidas), a padronização é indispensável.

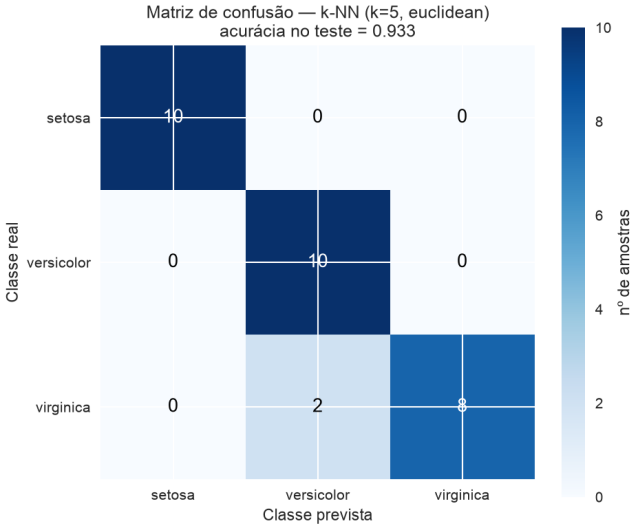


Figura 6. Matriz de confusão no conjunto de teste (linhas: classe real; colunas: classe prevista).

VIII. Conclusão

O ciclo completo de experimentos no dataset Íris mostrou que a estatística descritiva e a análise de relações entre variáveis já revelam a estrutura do problema: pétalas separam bem as espécies (padrão trimodal, *setosa* isolada), enquanto sépalas separam pouco, e as correlações comprimento $\times$ largura variam de fracas a fortes conforme a espécie e o órgão da flor. A PCA condensou 95,8% da variância em duas componentes, cuja projeção reproduz a geometria das classes vista nos pares de variáveis.

O classificador k-NN com padronização, $k = 5$ e distância euclidiana — selecionado por validação cruzada — alcançou 93,3% de acurácia no teste, com erros restritos à fronteira *versicolor–virginica*, coerentes com a sobreposição observada na análise exploratória. Os resultados ilustram na prática conceitos das aulas: memorização vs. generalização, papel da métrica de distância e do escalonamento, seleção de hiperparâmetros por validação cruzada e avaliação honesta em conjunto de teste separado. Como trabalho futuro, seria natural comparar o k-NN com outros classificadores (e.g., SVM, árvores de decisão) e usar as duas primeiras componentes principais como entrada do classificador.

Referências

[1] E. Todt, "Computer Vision and Perception: Recognition," Aula 1, Departamento de Informática, UFPR, 2026.

[2] E. Todt, "Computer Vision and Perception: Classification – kNN," Aula 2, Departamento de Informática, UFPR, 2026.

[3] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.

[4] "Iris Data Set," UCI Machine Learning Repository. [Online]. Available: https://archive.ics.uci.edu/ml/datasets/iris

[5] I. T. Jolliffe e J. Cadima, “Principal component analysis: a review and recent developments,” *Philosophical Transactions of the Royal Society A*, vol. 374, 2016.
[6] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.